

Wie bringe ich meine erste GPT App auf Prod?


Vorsicht vor dem Neffen des Chefs

Christian Hidber, bSquare

Magdeburger Dev-Days, Mai 2025


Boss:

my nephew does GPT too...



LLM Intro


How does a Decoder Model work ?



- Depends on users goal
- Unique for each chat & user
- Contains the chat history
- «**the context**»

- Trained on huge datasets
- Does not change
- Same for all users
- «**the model**»

How does a Decoder Model work ?




- Depends on users goal
- Unique for each chat & user
- Contains the chat history
- «**the context**»

- Trained on huge datasets
- Does not change
- Same for all users
- «**the model**»

- Single «word»
- Depends on context and model
- «**the token**»

How does a Decoder Model work ?




- Depends on users goal
- Unique for each chat & user
- Contains the chat history
- **«the context»**

- Trained on huge datasets
- Does not change
- Same for all users
- **«the model»**

- Single «word»
- Depends on context and model
- **«the token»**

Q: what is pluvia ?
A: Pluvia is a latin




...

- Depends on users goal
- Unique for each chat & user
- Contains the chat history
- «the context»

- Trained on huge datasets
- Does not change
- Same for all users
- «the model»

- Single «word»
- Depends on context and model
- «the token»

How does a Decoder Model work ?




- Depends on users goal
- Unique for each chat & user
- Contains the chat history
- «the context»


- Trained on huge datasets
- Does not change
- Same for all users
- «the model»

- Single «word»
- Depends on context and model
- «the token»


Naïve Approach



Retrieval Augmented Generation



Demo: RAG Applications



Choosing an application

Low Risk, but nice benefit

Low Risk

- What is the worst thing that could happen and how to mitigate that?
- Low profile
- Failures should be ok
- Human in the loop

Nice Benefit

- Impossible to do by humans or
- Humans don't like to do
- Let the whole organization learn
- Management likes it, but is afraid
- Can it be used for (internal) marketing?

Artikelinformationen


Artikelnummer	Artikel
461.015.00.1	GIS Wandanbindung
461.022.00.1	GIS Verbindungslasche 13 x 3 x 0,4 cm
461.025.00.1	GIS Paneel 130 x 60 x 1,8 cm
461.025.00.1	GIS Paneel 130 x 60 x 1,8 cm (GIS Tragsyst
461.030.00.1	Paneelschraube 4,2 x 35 mm Gr. 200 Stck
461.030.00.1	Paneelschraube 4,2 x 35 mm Gr. 200 Stck

Beschreibung
Der Artikel GIS Wandanbindung dient zur sicheren und stabilen Befestigung des Geberit GIS Tragsystems an der Baukörperwand. Er ermöglicht den Ausgleich von Bautoleranzen durch flexible, punktuelle Befestigung. Zudem sorgt er für eine wirksame Schallentkopplung zwischen Tragsystem und Baukörper durch Kork-Schalldämmplatten. Dies gewährleistet eine dauerhafte und geräuscharme Verbindung.

Verwendungszwecke
- Zum Aussteifen und Befestigen von Geberit GIS Tragsystemen am Baukörper

Eigenschaften
- Stufenlos von Hand verschiebbar

Technische Eigenschaften
Dieser Text wurde von einer KI erzeugt und / oder übersetzt. Er kann darum überraschend oder inkorrekt sein. Überprüfen Sie die Korrektheit anhand der Geberit Dokumentation.



Ge... Ass... Auf... 3D... Arti... Pro...

Low Risk, but nice benefit



Artikelinformationen

Artikelnummer	Artikel
461.015.00.1	GIS Wandanbindung
461.022.00.1	GIS Verbindungslasche 13 x 3 x 0,4 cm
461.025.00.1	GIS Paneel 130 x 60 x 1,8 cm
461.025.00.1	GIS Paneel 130 x 60 x 1,8 cm (GIS Tragsyst
461.030.00.1	Paneelschraube 4,2 x 35 mm Gr. 200 Stck
461.030.00.1	Paneelschraube 4,2 x 35 mm Gr. 200 Stck

Beschreibung

Der Artikel GIS Wandanbindung dient zur sicheren und stabilen Befestigung des Geberit GIS Tragsystems an der Baukörperwand. Er ermöglicht den Ausgleich von Bautoleranzen durch flexible, punktuelle Befestigung. Zudem sorgt er für eine wirksame Schallentkopplung zwischen Tragsystem und Baukörper durch Kork-Schalldämmplatten. Dies gewährleistet eine dauerhafte und geräuscharme Verbindung.

Verwendungszwecke


- Zum Aussteifen und Befestigen von Geberit GIS Tragsystemen am Baukörper

Eigenschaften

- Stufenlos von Hand verschiebbar

Technische Eigenschaften

Dieser Text wurde von einer KI erzeugt und / oder übersetzt. Er kann darum überraschend oder inkorrekt sein. Überprüfen Sie die Korrektheit anhand der Geberit Dokumentation.



From Prompt Hacking to Production

Writing a PoC vs. Engineering Task


Ad-hoc prompting is something very different from writing a prompt for a service

With ad-hoc prompting

- you can immediately see if it works.
- there's a high level of human oversight.
- it only needs to work for a specific example

With prompting for a system

- It needs to generalize for all expected use cases
- Has no or less human supervision
- Stability is expected



Evaluation

Evaluation on text results

User:
Asking a Question




Question

- What is Pluvia ?

Answer

- Pluvia is a latin word meaning rainfall.
- The latin word for rainfall.
-


=> equality not an option



Llm:
Generating an Answer

Human Eval


Evaluation on text results




Evaluation Criteria:

- with Ground Truth
 - Correct
 - Complete
- without Ground Truth
 - Concise
 - Relevant
 - Contradiction free
 - Language
 - Style
 - ...
 - Generation successful

Evaluation on text results



Demo:
Evaluation Notebook



Online Eval: Example

```
[07:56:37 INF] POST "https://[REDACTED].azurewebsites.net/"eval succeeded in 4.91s with response={
  "Metadata": {
    "Answer": "Der Artikel Sigma20 Bet  tigungsplatte dient zur Steuerung der 2-Mengen-Sp  lung bei Geberit UP-Sp  lk  sten. Sie erm  g.",
    "CreateDate": "2024-09-10T07:56:37.744166Z",
    "DeepEval": {
      "Answer_Relevancy": {
        "reason": "The score is 1.00 because the response directly addresses the purpose of the Sigma20 BetPl. article without any irre.",
        "score": 1.0
      },
      "Conciseness_(GEval)": {
        "reason": "The output is somewhat concise but includes unnecessary details about materials and suitability that could be omitted",
        "score": 0.6
      },
      "Contextual_Relevancy": {
        "reason": "The score is 0.33 because the context discusses various models and specifications of flushing systems but does not p",
        "score": 0.3333333333333333
      },
      "Faithfulness": {
        "reason": "The score is 0.80 because the actual output inaccurately generalizes the material of the Bet  tigungsplatte, stating",
        "score": 0.8
      }
    },
    "ElapsedSeconds": 4.85,
    "EvalType": "deep_eval",
    "EvalVersion": "240903",
    "Input": "Wozu dient der Artikel Sigma20 BetPl., f  r 2-Mengen-Sp  lung wei   / wei   matt ?"
  },
  "Metrics": {
    "Answer_Relevancy": 1.0,
    "Conciseness_(GEval)": 0.6,
    "Contextual_Relevancy": 0.3333333333333333,
    "Faithfulness": 0.8
  },
  "Score": 0.6833333333333333
}
```

PDF Tables

7.8 Dimensionierung der Geberit Pluvia Dachentwässerung

7.8.1 Grundlagen

Grundlage zur Leitungsberechnung für eine Unterdruckdachentwässerung ist die Bernoulli-Gleichung.

Daniel Bernoulli entdeckte die Beziehung zwischen der Fließgeschwindigkeit eines Fluids und dessen Drucks, demzufolge bei einem engeren Durchmesser ein Geschwindigkeitsanstieg von einem Druckabfall begleitet wird. Als Ausgangsformel für die Dimensionierung ergibt sich:

Δh_{geo} · ρ · g = Δp

Δh_{geo} Höhendifferenz zwischen Dachabdichtung und teilgefüllter Leitung
ρ Dichte des Wassers bei 10°C: 1000 kg/m³
g Fallbeschleunigung 9,81 m/s²
Δp verfügbarer Druck

In der Berechnung werden alle Fließwege (Stromlinien) betrachtet. Die Stromlinien beginnen immer an der Oberkante der Wasserlinie über dem jeweiligen Dachwassereinfluss und enden beim Übergang in die Freispegelentwässerung.

Wie bei allen Leitungsberechnungen entstehen Druckverluste durch Rohrreibung und Einzelwiderstände (R · l + Z). Diese Druckverluste müssen überwunden werden, damit das System der Druckentwässerung richtig funktioniert. Das heißt, die Strömungsverluste sind mit dem verfügbaren Druck gleich zu setzen.

Δh_{geo} · ρ · g = Σ (R · l + Z)

Im Auslegungsfall darf die Abweichung dieser beiden Formeln pro Fließweg nicht mehr oder weniger als 100 hPa (100 mbar) betragen. Die Völlfüllung des Rohres kann somit nur durch den richtigen hydraulischen Abgleich der einzelnen Fließwege erreicht werden. Nach DIN 1986-100 ist für eine Druckströmungsdachentwässerung immer der hydraulische Abgleich vorzunehmen. Den hydraulischen Abgleich übernimmt eine Software wie zum Beispiel Geberit ProPlanner.

i Sind auf Dachflächen Kühlaggregate nach § 19 (4) AwSV installiert, gelten die Regelungen der DIN 1986-100 Anhang C (siehe auch → Kapitel 8.3 ab Seite 101).

7.8.2 Hauptentwässerung

Zur Berechnung der Regenwassermenge wird folgende Formel benötigt:

Q_R = (A · r · C_S) / 10000

Q_R Regenwassermenge [l/s]
A Abflusswirksame Fläche [m²]
r Regenspende (gemäß KOSTRA-DWD 2010¹, ausgewählte Orte auch in der DIN 1986-100)
C_S Spitzenabflussbeiwert (gemäß "Dachaufbauten und Abflussbeiwerte nach DIN 1986-100, Tabelle 9")

Tabelle 85: Dachaufbauten und Abflussbeiwerte nach DIN 1986-100, Tabelle 9

Art der Flächen		Spitzenabflussbeiwert C _S	Mittlerer Abflussbeiwert C _M
Wasserundurchlässige Flächen, z. B.	Flachdach (≤ 3°)	1,0	0,9
	Betonflächen	1,0	0,9
	Rampen	1,0	1,0
	Befestigte Flächen mit Fugendichtung	1,0	0,8
	Schwarzdecken (Asphalt)	1,0	0,9
	Pflaster mit Fugenvergruss	1,0	0,8
Begrünte Dachflächen	Kiesschüttdächer	0,8	0,8
	Für Intensivbegrünungen ab 30 cm Aufbau- dicke (≤ 5°)	0,2	0,1
	Für Extensivbegrünungen ab 10 cm Aufbau- dicke (≤ 5°)	0,4	0,2
	Für Extensivbegrünungen unter 10 cm Aufbau- dicke (≤ 5°)	0,5	0,3
	Für Extensivbegrünung (> 5°)	0,7	0,4


Als abflusswirksame Fläche A ist zur Berechnung die im Grundriss dargestellte Dachfläche anzunehmen.

Bei Objekten mit hohen Fassaden ist durch den Planer zu prüfen, ob der durch den Wind gegen die Fassade getriebene Regen Einfluss auf die Dachentwässerungsanlage hat. Ist dies der Fall, muss die Dachfläche nach DIN EN 12056-03 Abschnitt 4.3 Tabelle 3 in der Berechnung berücksichtigt werden.

1. Urheber: dwd, Deutscher Wetterdienst, Bezug: CD-ROM über ITWH, Hannover (→ http://www.itwh.de/S_kostr.htm)

Tabelle 85: Dachaufbauten und Abflussbeiwerte nach
DIN 1986-100, Tabelle 9

	Art der Flächen	Spitzen- abfluss- beiwert	Mittlerer Abfluss- beiwert
		C _S	C _M
Wasser- undurch- lässige Flächen, z. B.	Flachdach ($\leq 3^\circ$)	1,0	0,9
	Betonflächen	1,0	0,9
	Rampen	1,0	1,0
	Befestigte Flächen mit Fugendichtung	1,0	0,8
	Schwarzdecken (Asphalt)	1,0	0,9
	Pflaster mit Fugenver- guss	1,0	0,8
	Kiesschüttdächer	0,8	0,8
Begrünte Dach- flächen	Für Intensivbegrünun- gen ab 30 cm Aufbau- dicke ($\leq 5^\circ$)	0,2	0,1
	Für Extensivbegrünun- gen ab 10 cm Aufbau- dicke ($\leq 5^\circ$)	0,4	0,2
	Für Extensivbegrünun- gen unter 10 cm Aufbau- dicke ($\leq 5^\circ$)	0,5	0,3
	Für Extensivbegrünung ($> 5^\circ$)	0,7	0,4



Art der Flächen Spitzen-\nabfluss-\nbeiwert
\nC_S
Mittlerer \nAbfluss-\nbeiwert \nC_M
\nWasser-
\nundurch-lässige Flächen, z. B. Flachdach ($\leq 3^\circ$) 1,0
0,9
\nBetonflächen 1,0 0,9
\nRampen 1,0 1,0
\nBefestigte
Flächen mit Fugendichtung 1,0 0,8
\nSchwarzdecken
(Asphalt) 1,0 0,9
\nPflaster mit Fugenver-
guss 1,0 0,8
\nKiesschüttdächer 0,8 0,8
\nBegrünte Dach-
flächen
Für Intensivbegrünun-gen ab 30 cm Aufbau-
dicke ($\leq 5^\circ$) 0,2 0,1
Für Extensivbegrünun-gen ab 10
cm Aufbau-dicke ($\leq 5^\circ$) 0,4 0,2
Für Extensivbegrünun-
gen unter 10 cm Aufbau-dicke ($\leq 5^\circ$) 0,5 0,3
Für
Extensivbegrünung ($> 5^\circ$) 0,7 0,4

Tabelle 85: Dachaufbauten und Abflussbeiwerte nach
DIN 1986-100, Tabelle 9

	Art der Flächen	Spitzen- abfluss- beiwert	Mittlerer Abfluss- beiwert
		C _S	C _M
Wasser- undurch- lässige Flächen, z. B.	Flachdach (≤ 3°)	1,0	0,9
	Betonflächen	1,0	0,9
	Rampen	1,0	1,0
	Befestigte Flächen mit Fugendichtung	1,0	0,8
	Schwarzdecken (Asphalt)	1,0	0,9
	Pflaster mit Fugenver- guss	1,0	0,8
	Kiesschüttdächer	0,8	0,8
Begrünte Dach- flächen	Für Intensivbegrünun- gen ab 30 cm Aufbau- dicke (≤ 5°)	0,2	0,1
	Für Extensivbegrünun- gen ab 10 cm Aufbau- dicke (≤ 5°)	0,4	0,2
	Für Extensivbegrünun- gen unter 10 cm Aufbau- dicke (≤ 5°)	0,5	0,3
	Für Extensivbegrünung (> 5°)	0,7	0,4





Table Caption:
Tabelle 85: Dachaufbauten und Abflussbeiwerte....


Table Summary:
Die Tabelle beschreibt.....

Table CSV:
,Art der Flächen,Spitzenabflussbeiwert,...
Wasser-undurchlässige Flächen, Flachdach (<=3),1.0,0.9
....

Demo:
Azure Document Intelligence...



PDF Tables: multi vector

[illegible]

Art der Flächen Spitzen-Inabfluss-Inbeiwert
 \nC\nSMittlerer \nAbfluss-Inbeiwert \nC\nM\nWasser-
 \nundurch-lässige Flächen, z. B. Flachdach ($\leq 3^\circ$) 1,0
 0,9\nBetonflächen 1,0 0,9\nRampen 1,0 1,0 1,0\nBefestigte
 Flächen mit Fugendichtung 1,0 0,8\nSchwarzdecken
 (Asphalt) 1,0 0,9\nPflaster mit Fugenver-

guss 1,0 0,8\%Kiesschüttddächer 0,8 0,8\%Begrünte Dach-
flächenFür Extensivbegrünun-gen ab 30 cm Aufbau-
dicke ($\leq 5^\circ$) 0,2 0,1\%Für Extensivbegrünun-gen ab 10
cm Aufbau-dicke ($\leq 5^\circ$) 0,4 0,2\%Für Extensivbegrünun-
gen unter 10 cm Aufbau-dicke ($\leq 5^\circ$) 0,5 0,3\%Für
Extensivbegrünung ($> 5^\circ$) 0,7 0,4\%

Table Caption:

Tabelle 85: Dachaufbauten und Abflussbeiwerte...

Table Summary:

Die Tabelle beschreibt....

Table CSV:

Wasser-undurchlässige Flächen, Flachdach (<=3).1.0.0.9



Vector DB:
Searching facts matching
the question

You are an expert in


What is Pluvia ?

Use the following facts:



System Architecture old vs new school

System Architecture: old vs new school



Tool Calling




What is the ArtNo of a bend ? I am only interested in 90 degree ones.



What is the ArtNo of a bend ? I am only interested in 90 degree ones.

```
{...  
«ArtNo» : «370.055.16.1»,  
«Text»: «Bend 90°, d200, PE,...»  
...}
```



The ArtNo of a bend 90 with d200 is 370.055.16.1

GetArticle(«Bend 90°»)



Tool Calling



What is the ArtNo of a bend ? I am only interested in 90 degree ones.

```
{...
«type» : «function»,
«name» : «GetArticle»,
«description» : «Yields the ArtNo...»
«args» : {«article text» : «string»}
...}
```




```
{
  "type": "function_call",
  "name": "GetArticle ",
  "args": {«article text»:«Bend 90°»}
}
```

What is the ArtNo of a bend ? I am only interested in 90 degree ones.

```
{...
«type» : «function»,
«name» : «GetArticle...»,
«description» : «Yields the ArtNo...»

"type": "function_call_output",
"output": { «ArtNo» : «370.055.16.1»,
           «Text» : «Bend 90°, d200, PE,...» }
...}
```



The ArtNo of a bend 90 with d200 is 370.055.16.1

List Tools


Generisch

Call Tool


GetArticle(«Bend 90°»)




Tool Calling: Model Context Protocol



System Architecture: Model Context Protocol




Demo:
Model Context Protocol



Wrap Up

Wrap Up



None the less

beware of your boss's nephew...

Thank you

